UNIVERSIDAD AUTÓNOMA DE SANTO DOMINGO (UASD)
y UNIVERSIDAD MIGUEL HERMANDEZ (UMH)
FACULTAD DE CIENCIAS - ESCUELA DE INFORMÁTICA
UNIDAD DE POSTGRADO Y EDUCACIÓN PERMANENTE

Doctorado:
PhD en Inteligencia Artificial y Aprendizaje Automático

Asignatura:
INF-9005: Algoritmos de Clasificación en Machine Learning

Práctica 1:
Análisis del estado del arte en algoritmos de Machine Learning

Línea de Investigación:
Árboles de Decisión y Regresión Logística: análisis del compromiso entre interpretabilidad del modelo y rendimiento predictivo en problemas de clasificación.

Docente:
Dr. Ana Belén

Doctoranda:
Romery Alberto Monegro

Santo Domingo, D. N.
19 de abril del 2026

Resumen

Este trabajo presenta una revisión del estado del arte sobre dos de los algoritmos más utilizados en clasificación supervisada: los árboles de decisión y la regresión logística. El eje de la revisión es la tensión entre interpretabilidad y rendimiento predictivo, un debate que ha ganado protagonismo con la llegada de marcos regulatorios como el Reglamento General de Protección de Datos de la Unión Europea y la Ley de Inteligencia Artificial. A partir de artículos científicos, monografías de referencia y documentación técnica se examinan los fundamentos matemáticos de ambos modelos, su evolución a lo largo de las últimas cuatro décadas y las principales comparaciones empíricas publicadas en los últimos años. El análisis muestra que la disyuntiva clásica, según la cual mayor precisión supone sacrificar interpretabilidad, no es universal: en muchos escenarios prácticos los modelos transparentes compiten de cerca con los modelos opacos cuando se les optimiza con cuidado. El trabajo cierra con una propuesta de líneas futuras de investigación centradas en modelos híbridos, métricas formales de interpretabilidad, árboles óptimos y la integración del análisis de eficiencia computacional en la selección de modelos.

Palabras clave: árboles de decisión, CART, regresión logística, interpretabilidad, XAI, clasificación, Machine Learning, regularización.

Índice

1. Introducción

2. Revisión bibliográfica y estado del arte

    2.1. Trayectoria de los árboles de decisión

    2.2. Trayectoria de la regresión logística

    2.3. El debate interpretabilidad-rendimiento en la literatura reciente

3. Fundamentos matemáticos

    3.1. Árboles de decisión: criterios de partición y poda

    3.2. Regresión logística: función sigmoide y estimación

    3.3. Métricas de evaluación para clasificación

4. Análisis comparativo

5. Líneas futuras de investigación

6. Conclusiones

7. Referencias bibliográficas

1. Introducción

La expansión del aprendizaje automático hacia dominios sensibles como la medicina, las finanzas, la justicia y la educación ha cambiado las reglas del juego en la selección de modelos. Ya no basta con optimizar una métrica de precisión: la decisión de qué algoritmo emplear tiene consecuencias operativas, éticas y legales.

Dentro del universo de clasificadores supervisados, los árboles de decisión y la regresión logística ocupan un lugar singular. Ambos llevan décadas aplicándose en la práctica y se han convertido en puntos de referencia en el espectro que va desde la interpretabilidad intrínseca hasta la exigencia de un rendimiento elevado. El árbol de decisión ofrece una representación visual, con reglas condicionales que cualquier persona familiarizada con el dominio puede seguir. La regresión logística, por su parte, aporta una formulación estadística sólida, coeficientes interpretables como razones de momios y probabilidades bien calibradas.

La tensión entre interpretabilidad y rendimiento predictivo no es nueva, pero ha cobrado un protagonismo particular en la última década. El auge de los métodos de ensamble basados en árboles, junto con las redes neuronales profundas, consolidó la idea de que precisión e interpretabilidad son objetivos enfrentados. Rudin (2019) y otros investigadores han cuestionado esa idea con argumentos teóricos y empíricos, abriendo un debate que sigue vigente. Al mismo tiempo, regulaciones como el Reglamento General de Protección de Datos (RGPD) de la Unión Europea y la Ley de Inteligencia Artificial (AI Act) han elevado la interpretabilidad de atributo deseable a requisito normativo en sistemas clasificados como de alto riesgo.

En este escenario, la comparación entre árboles de decisión y regresión logística resulta pertinente por varios motivos. Primero, ambos son modelos intrínsecamente interpretables, aunque con mecanismos distintos. Segundo, sus supuestos teóricos difieren: la regresión logística es un modelo paramétrico con frontera de decisión lineal en el espacio logit, mientras que el árbol es un modelo no paramétrico que particiona el espacio de características en regiones rectangulares. Y tercero, sus perfiles de sobreajuste, estabilidad y manejo de no linealidades son opuestos, lo que los convierte en complementos más que en competidores.

El presente trabajo revisa el estado del arte de esta línea temática. Examina los fundamentos matemáticos de ambos algoritmos, recorre su evolución histórica, analiza la evidencia empírica reciente sobre el compromiso interpretabilidad-rendimiento y propone líneas futuras de investigación. La revisión se apoya en artículos de revistas indexadas, conferencias de referencia como NeurIPS, KDD y FAccT, monografías clásicas y documentación técnica de bibliotecas ampliamente utilizadas.

2. Revisión bibliográfica y estado del arte

2.1. Trayectoria de los árboles de decisión

Los árboles de decisión tienen una historia larga en el aprendizaje estadístico. Breiman et al. (1984) formalizaron el algoritmo CART (Classification and Regression Trees) y establecieron los pilares que siguen vigentes hoy: particiones binarias recursivas, criterios de impureza basados en el índice de Gini y una estrategia de poda por complejidad de costo para controlar el sobreajuste. La obra es referencia obligada en la literatura y marcó el tránsito del árbol como heurística ad hoc al árbol como herramienta estadística con garantías teóricas.

En paralelo, Quinlan (1986) propuso ID3, un algoritmo que utilizaba la ganancia de información derivada de la entropía de Shannon como criterio de partición. Su evolución natural, C4.5 (Quinlan, 1993), incorporó el manejo de atributos continuos, valores faltantes y la conversión del árbol en un conjunto de reglas simplificadas. C4.5 se convirtió en uno de los algoritmos más citados de la historia del Machine Learning y quedó incluido en la lista de los diez algoritmos fundamentales de minería de datos (Wu et al., 2008).

A partir de los años noventa, el foco de la investigación se desplazó hacia los métodos de ensamble. Breiman (1996) introdujo el bagging, Breiman (2001) formalizó los Random Forests y Friedman (2001) sistematizó el gradient boosting. Los tres enfoques demostraron que un conjunto de árboles débiles podía superar con creces a un árbol único en precisión, al precio de sacrificar la inspección directa del modelo. Esta ruptura entre un árbol legible y un bosque de cientos de árboles es justamente el germen del debate moderno sobre interpretabilidad.

En años recientes el interés por el árbol individual ha resurgido, esta vez desde la óptica de la inteligencia artificial explicable (XAI). Bertsimas y Dunn (2017) propusieron los árboles de clasificación óptimos mediante programación entera mixta, un cambio de paradigma frente a la inducción voraz tradicional. Verwer y Zhang (2019) refinaron la formulación con programación lineal binaria y mejoraron la escalabilidad. Ambos trabajos muestran que es posible obtener árboles más pequeños y precisos cuando se abandona la heurística clásica, lo que abre la puerta a una nueva generación de clasificadores interpretables competitivos.

El trabajo de Assis, Dantas y Andrade (2025), publicado en Journal of Reliable Intelligent Environments, compara empíricamente modelos transparentes (incluidos los árboles de decisión) frente a modelos opacos en un entorno inteligente. Los resultados respaldan la tesis de que un árbol bien entrenado puede ser competitivo en precisión y tiempo de respuesta, con la ventaja añadida de su capacidad explicativa.

2.2. Trayectoria de la regresión logística

La regresión logística tiene raíces anteriores al Machine Learning moderno. Joseph Berkson popularizó el uso de la función logit en los años cuarenta y cincuenta para modelar respuestas binarias en contextos biológicos, pero fue Nelder y Wedderburn (1972) quienes dieron el paso decisivo al formular el modelo dentro del marco unificador de los modelos lineales generalizados. Este encuadre teórico permitió conectar la regresión logística con la regresión lineal, la Poisson y la gamma mediante una función de enlace y una familia exponencial común. El texto de Hosmer, Lemeshow y Sturdivant (2013), en su tercera edición, sigue siendo la referencia práctica por excelencia para aplicar el modelo en investigación aplicada.

Durante décadas la regresión logística fue el clasificador preferido en medicina, epidemiología, finanzas y ciencias sociales. Su combinación de probabilidades calibradas, coeficientes interpretables como razones de momios y una base estadística sólida explicaba su popularidad. La aparición de algoritmos más flexibles no desplazó a la regresión logística sino que consolidó su papel como benchmark contra el cual se mide cualquier clasificador nuevo.

La regularización supuso un avance decisivo. Tibshirani (1996) propuso la penalización Lasso, que produce modelos dispersos al forzar coeficientes a cero. La penalización Ridge, ya conocida en regresión lineal, se adaptó al contexto logístico para estabilizar las estimaciones ante colinealidad. El Elastic Net (Zou y Hastie, 2005) combinó ambas penalizaciones en una formulación convexa que equilibra dispersión y estabilidad. Estas técnicas extendieron la regresión logística al dominio de alta dimensionalidad, donde el número de predictores puede ser mayor que el número de observaciones.

Una línea de investigación especialmente relevante para esta revisión es la de los modelos híbridos que intentan incorporar efectos no lineales sin renunciar a la estructura logística. Landwehr, Hall y Frank (2005) propusieron los Logistic Model Trees, un árbol de decisión cuyas hojas contienen modelos de regresión logística ajustados por LogitBoost. Más reciente es la propuesta de Dumitrescu et al. (2022), el modelo PLTR (Penalised Logistic Tree Regression), que utiliza reglas extraídas de árboles de decisión de profundidad reducida como predictores en una regresión logística penalizada. PLTR captura interacciones no lineales manteniendo la interpretabilidad del modelo logístico y ha demostrado un rendimiento competitivo frente a Random Forest en scoring crediticio. Park et al. (2023) plantean el modelo FS-LMT, una variante que selecciona las divisiones del árbol mediante un criterio de separabilidad de clases en el espacio de la regresión logística, evitando el ajuste exhaustivo de modelos hijos y reduciendo de forma notable el costo computacional.

2.3. El debate interpretabilidad-rendimiento en la literatura reciente

La idea de que existe un trade-off inevitable entre precisión e interpretabilidad ha sido durante años un supuesto no discutido en la comunidad. Doshi-Velez y Kim (2017) pusieron el dedo en la llaga al señalar que la literatura carece de una definición rigurosa de interpretabilidad, lo que dificulta cualquier análisis formal del compromiso.

Rudin (2019) dio un paso más con un artículo que se ha convertido en referencia obligada. Su tesis es clara: el rendimiento superior de los modelos de caja negra frente a los modelos interpretables es, en muchos dominios, marginal o inexistente cuando estos últimos se optimizan con cuidado. Rudin argumenta que en decisiones de alto riesgo, donde el error tiene consecuencias

graves para personas concretas, debe preferirse un modelo interpretable aunque ceda décimas de precisión.

La evidencia empírica reciente ha matizado el debate en ambas direcciones. Bell et al. (2022), en un estudio presentado en la ACM Conference on Fairness, Accountability, and Transparency, evaluaron la explicabilidad percibida por usuarios no expertos en dos contextos de política pública. Su hallazgo es más sutil de lo que la dicotomía caja negra vs. modelo transparente sugiere: los modelos opacos no son universalmente menos explicables para un usuario humano, y los modelos interpretables no siempre se entienden mejor. El problema de la interpretabilidad es, en buena medida, un problema de interacción humano-máquina. Yin y Babic (2024) proponen una reformulación del trade-off: en lugar de preguntarse si la precisión sufre cuando se exige interpretabilidad, conviene preguntarse en qué condiciones presentar un modelo más interpretable (aunque sea menos preciso) beneficia el rendimiento colaborativo del equipo humano-algoritmo.

Desde la teoría del aprendizaje, Dziugaite, Ben-David y Roy (2020) modelaron la interpretabilidad como una restricción sobre el espacio de hipótesis y analizaron las implicaciones estadísticas de esa restricción. Su marco permite razonar de forma precisa sobre cuándo la interpretabilidad supone un costo en exceso de riesgo estadístico y cuándo no. El trabajo de Assis et al. (2025), en la misma línea empírica, compara seis modelos (KNN, árboles, regresión logística, CNN, Random Forest y SVM) sobre conjuntos de datos representativos y concluye que los modelos transparentes son competitivos en precisión y tiempo de respuesta, con la ventaja adicional de su capacidad explicativa.

En el terreno de las técnicas XAI post-hoc, SHAP (Lundberg y Lee, 2017) y LIME (Ribeiro et al., 2016) se han convertido en herramientas estándar para atribuir importancia a variables en modelos opacos. Wachter, Mittelstadt y Russell (2018) proponen un enfoque distinto basado en explicaciones contrafactuales, argumentando que este tipo de explicación se ajusta mejor a la noción de derecho a explicación recogida en el RGPD. Todas estas técnicas, sin embargo, comparten una limitación: producen aproximaciones locales del comportamiento del modelo que no capturan su lógica global. Este argumento refuerza, para Rudin (2019) y otros autores, la preferencia por modelos intrínsecamente interpretables en dominios sensibles.

Molnar (2022) recoge el conjunto de métodos disponibles en un texto accesible que se ha convertido en referencia tanto para practitioners como para investigadores. Su libro ilustra con claridad que el debate no es binario sino un continuo en el que intervienen el tipo de datos, el perfil del usuario final y las exigencias del dominio.

3. Fundamentos matemáticos

3.1. Árboles de decisión: criterios de partición y poda

3.1.1. Estructura del árbol y proceso de inducción

Un árbol de decisión es un modelo no paramétrico que particiona de forma recursiva el espacio de características $X \subseteq \mathbb{R}^p$ en regiones disjuntas y asigna a cada región una predicción de clase. Formalmente, el árbol define una función $h: \mathbb{R}^p \to Y$, donde Y denota el conjunto de clases posibles.

El proceso de construcción sigue el paradigma TDIDT (Top-Down Induction of Decision Trees). Se parte del nodo raíz, que contiene todos los ejemplos de entrenamiento, y en cada paso se elige el atributo x_j y el umbral t que maximizan la reducción de impureza al dividir el nodo en dos subconjuntos (para CART) o más (para ID3 y C4.5). El proceso continúa hasta alcanzar un criterio de parada, como una profundidad máxima, un mínimo de observaciones por nodo o una ganancia de impureza insuficiente.

3.1.2. Criterios de impureza

El criterio de Gini, empleado por CART, mide la probabilidad de que una observación elegida al azar del nodo sea clasificada incorrectamente si se asigna según la distribución de clases del nodo:

$$Gini(t) = 1 - \Sigma_k \, p(k|t)^2$$

donde p(k|t) es la proporción de observaciones de la clase k en el nodo t. Un nodo puro, compuesto por una única clase, tiene Gini = 0. Un nodo con distribución uniforme sobre K clases alcanza Gini = 1 − 1/K, el valor máximo para K clases.

El criterio de entropía de Shannon, utilizado por ID3 y C4.5, se define como:

$$H(t) = -\Sigma_k\, p(k|t) \cdot \log_2 p(k|t)$$

La ganancia de información al aplicar la división s sobre el nodo t es:

$$\Delta I(s,t) = I(t) - \Sigma_i\, (N_i/N) \cdot I(t_i)$$

donde I es la función de impureza (Gini o entropía), N el número total de observaciones en el nodo padre y N_i el número de observaciones en el nodo hijo i. El algoritmo elige la división s* que maximiza $\Delta I(s,t)$.

La ganancia de información tiende a favorecer atributos con muchos valores distintos, lo que puede producir árboles desequilibrados. Quinlan corrigió este sesgo en C4.5 mediante la razón de ganancia, que normaliza por la entropía del atributo divisor:

$$GainRatio(s,t) = \Delta I(s,t) \,/\, H(atributo_s)$$

3.1.3. Poda del árbol

Los árboles de decisión son especialmente proclives al sobreajuste cuando se construyen sin restricciones. La poda es el mecanismo de regularización central para controlar la complejidad del modelo.

La poda por complejidad de costo, implementada en CART, introduce un parámetro $\alpha \geq 0$ que penaliza el número de hojas del árbol:

$$R_\alpha(T) = R(T) + \alpha \cdot |\tilde{T}|$$

donde R(T) es el error de resustitución del árbol T y $|\tilde{T}|$ el número de nodos hoja. Para cada valor de α existe un único subárbol T(α) que minimiza R_α. La selección del valor óptimo de α se realiza mediante validación cruzada.

Frente a esta poda post-hoc, también existen estrategias de prepoda o early stopping que detienen el crecimiento del árbol cuando se alcanza una profundidad máxima, un mínimo de instancias por nodo o una ganancia por debajo de un umbral. Cada enfoque tiene ventajas: la prepoda es más económica en cómputo, mientras que la poda post-hoc suele producir árboles mejor generalizados porque explora primero el árbol completo.

3.2. Regresión logística: función sigmoide y estimación

3.2.1. El modelo logístico

La regresión logística es un modelo discriminativo para clasificación binaria que estima la probabilidad posterior P(Y=1|X=x) mediante la función logística, también conocida como sigmoide:

$$P(Y=1|x) = \sigma(z) = 1 / (1 + exp(-z))$$

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p = \beta_0 + \beta^T x$$

donde $\beta = (\beta_0, \beta_1, \ldots, \beta_p)^T$ es el vector de parámetros. La función sigmoide mapea cualquier número real al intervalo (0, 1), lo que permite interpretar su salida directamente como probabilidad.

3.2.2. La función logit y la interpretación de los coeficientes

El logaritmo de la razón de probabilidades (logit) es lineal en los predictores:

$$log(P(Y=1|x) / P(Y=0|x)) = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$$

Esta linealidad en el espacio logit es la clave de la interpretabilidad del modelo. El coeficiente β_j representa el cambio en el logit asociado a un incremento unitario en x_j, manteniendo constantes el resto de variables. La exponencial $\exp(\beta_j)$ es la razón de momios o odds ratio, e indica por qué factor se multiplica la razón P(Y=1)/P(Y=0) ante un incremento unitario de x_j. Esta propiedad hace que la regresión logística sea particularmente útil en epidemiología y medicina, donde el odds ratio tiene una interpretación clínica establecida.

3.2.3. Estimación por máxima verosimilitud

Los parámetros se estiman maximizando la función de log-verosimilitud sobre el conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^N$:

$$\ell(\beta) = \Sigma_i [y_i \cdot log(\sigma(\beta^T x_i)) + (1 - y_i) \cdot log(1 - \sigma(\beta^T x_i))]$$

Equivalentemente, se minimiza la pérdida de entropía cruzada binaria. Esta función es convexa en β, lo que garantiza la existencia de un mínimo global único. La optimización se lleva a cabo mediante métodos iterativos como el descenso por gradiente, L-BFGS o el método de

mínimos cuadrados iterativos reponderados (IRLS), siendo este último especialmente eficiente para problemas de tamaño moderado.

3.2.4. Regularización

Para prevenir el sobreajuste y mejorar la capacidad de generalización se añade un término de penalización a la función objetivo. Las variantes más habituales son la penalización L2 o Ridge, que reduce la magnitud de todos los coeficientes sin anularlos y mejora la estabilidad frente a multicolinealidad:

$$J(\beta) = -\ell(\beta) + \lambda \cdot \Sigma_j \beta_j^2$$

La penalización L1 o Lasso produce soluciones dispersas, anulando coeficientes de variables irrelevantes, lo que equivale a una selección automática de variables:

$$J(\beta) = -\ell(\beta) + \lambda \cdot \Sigma_j |\beta_j|$$

El Elastic Net combina ambas penalizaciones, buscando un equilibrio entre dispersión y estabilidad:

$$J(\beta) = -\ell(\beta) + \lambda \cdot [\, \alpha \cdot \Sigma_j |\beta_j| + (1 - \alpha) \cdot \Sigma_j \beta_j^2 \,]$$

El hiperparámetro λ controla la intensidad global de la penalización y en Elastic Net el parámetro $\alpha \in [0, 1]$ regula la mezcla L1/L2. Ambos se ajustan mediante validación cruzada.

3.3. Métricas de evaluación para clasificación

La evaluación de los modelos descansa en la matriz de confusión y en las métricas que se derivan de ella. La tabla 1 resume las más utilizadas en la literatura:

Tabla 1

Métricas de evaluación derivadas de la matriz de confusión

Métrica	Fórmula	Interpretación
Accuracy	(VP+VN)/(VP+VN+FP+FN)	Proporción de predicciones correctas

Métrica	Fórmula	Interpretación
Precisión	VP/(VP+FP)	Exactitud de las predicciones positivas
Recall (Sensibilidad)	VP/(VP+FN)	Cobertura de los positivos reales
Especificidad	VN/(VN+FP)	Cobertura de los negativos reales
F1-Score	2·(P·R)/(P+R)	Media armónica de precisión y recall
AUC-ROC	Área bajo la curva ROC	Discriminación global del modelo

La curva ROC (Receiver Operating Characteristic) representa la sensibilidad frente a 1 − especificidad al variar el umbral de decisión. El área bajo esta curva (AUC) es una métrica de discriminación robusta frente al desequilibrio de clases: un clasificador perfecto alcanza AUC = 1, uno aleatorio AUC = 0.5. En escenarios con clases desequilibradas, la AUC suele ofrecer una visión más honesta del rendimiento que la accuracy, que puede ser engañosa si la clase mayoritaria domina.

4. Análisis comparativo

La elección entre árbol de decisión y regresión logística no responde a una jerarquía absoluta. Depende de la naturaleza del problema, del volumen y calidad de los datos, del perfil del usuario final y de las restricciones regulatorias. La tabla 2 sintetiza las principales dimensiones de comparación.

Tabla 2

Comparación de propiedades clave entre árboles de decisión y regresión logística

Dimensión	Árbol de decisión	Regresión logística
Interpretabilidad	Reglas IF-THEN visualizables	Coeficientes y odds ratios
No linealidades	Captura nativa	Requiere ingeniería de variables
Probabilidades calibradas	No (requiere calibración)	Sí (por diseño)
Sobreajuste	Alto sin poda	Bajo con regularización
Estabilidad	Baja (alta varianza)	Alta
Datos faltantes	Manejo nativo	Requiere imputación
Variables categóricas	Manejo nativo	Requiere codificación
Escalado de datos	No necesario	Recomendable
Coste computacional	$O(n \cdot p \cdot \log n)$	$O(n \cdot p \cdot k)$ por iteración
Rendimiento predictivo	Moderado (árbol único)	Moderado-alto

Los resultados empíricos de Assis et al. (2025) respaldan la idea de que los modelos transparentes son competitivos con los opacos en muchos conjuntos de datos tabulares. En dominios donde la explicabilidad es exigida por ley (medicina, finanzas reguladas, justicia), el uso directo de modelos interpretables evita el problema de tener que explicar a posteriori lo que un modelo de caja negra realmente hizo.

Ahora bien, cuando el objetivo es el rendimiento máximo y la interpretabilidad pasa a segundo plano, los ensambles derivados del árbol (Random Forest, Gradient Boosting, XGBoost) suelen ofrecer mejoras sustanciales. El precio es la pérdida de inspección directa y un aumento del costo computacional, que puede ser determinante en aplicaciones con restricciones de recursos o latencia.

La regresión logística ocupa un espacio propio: cuando la frontera entre clases es aproximadamente lineal en el espacio logit, difícilmente un modelo más complejo la supera. Cuando esa linealidad no se cumple, los modelos híbridos como PLTR (Dumitrescu et al., 2022), Logistic Model Trees (Landwehr et al., 2005) o FS-LMT (Park et al., 2023) ofrecen un punto medio interesante: capturan no linealidades mediante estructuras de árbol y mantienen la interpretabilidad del modelo logístico. Esta convergencia entre ambas familias es, quizás, la línea más prometedora del área.

5. Líneas futuras de investigación

La revisión de la literatura permite identificar varias direcciones de trabajo con potencial significativo para los próximos años.

Modelos híbridos árbol-regresión. La convergencia entre árboles de decisión y regresión logística ya ha producido propuestas como PLTR (Dumitrescu et al., 2022), Logistic Model Trees (Landwehr et al., 2005) y FS-LMT (Park et al., 2023). Queda por explorar cómo combinar estas arquitecturas con técnicas modernas de regularización, cómo extenderlas a problemas multiclase con estructura jerárquica y cómo incorporar restricciones de equidad algorítmica sin sacrificar la interpretabilidad de las hojas.

Métricas formales de interpretabilidad. La ausencia de una definición operativa compartida de interpretabilidad es, según Doshi-Velez y Kim (2017) y Yin y Babic (2024), el cuello de botella principal del área. El desarrollo de métricas que cuantifiquen la complejidad estructural de un árbol, la consistencia de las explicaciones generadas por LIME o SHAP, la fidelidad de las aproximaciones locales o el rendimiento colaborativo humano-modelo es una necesidad urgente para poder comparar propuestas de forma objetiva.

Interpretabilidad en alta dimensionalidad. Conforme los conjuntos de datos incorporan más variables, el argumento de interpretabilidad del árbol individual o del coeficiente logístico se debilita: es difícil que una persona siga una regla con 40 condiciones o interprete 10 000

coeficientes. Combinar estos modelos con técnicas de reducción de dimensionalidad interpretable, selección de variables basada en información mutua o análisis de componentes supervisado es una línea especialmente relevante en genómica, procesamiento de lenguaje natural y bioinformática.

Árboles óptimos. La formulación de árboles de decisión como problemas de programación entera mixta (Bertsimas y Dunn, 2017; Verwer y Zhang, 2019) abre la puerta a clasificadores más pequeños, precisos y globalmente óptimos. La investigación activa se centra en mejorar la escalabilidad de estos algoritmos y en incorporar restricciones adicionales como equidad, robustez adversarial o interpretabilidad estructural. Bibliotecas como imodels ya incorporan algunas de estas técnicas.

Green AI e interpretabilidad. Schwartz et al. (2020) propusieron evaluar los modelos no solo por su rendimiento, sino también por su eficiencia computacional y huella de carbono. En este marco, la regresión logística y los árboles individuales presentan una ventaja natural frente a los ensambles y las redes neuronales profundas. Explorar el triple compromiso entre rendimiento, interpretabilidad y eficiencia es una dirección emergente con implicaciones prácticas considerables, sobre todo para organizaciones con restricciones presupuestarias.

Requisitos regulatorios y ética de la IA. La Ley de IA de la Unión Europea y el RGPD imponen exigencias concretas de explicabilidad a los sistemas clasificados como de alto riesgo. Wachter et al. (2018) plantean que las explicaciones contrafactuales encajan bien con estos requisitos. Queda por investigar de manera sistemática cómo los árboles de decisión y la regresión logística satisfacen cada una de las obligaciones del marco normativo, y en qué condiciones los modelos de caja negra con explicaciones post-hoc siguen siendo aceptables.

Aprendizaje incremental e interpretabilidad. Los modelos desplegados en producción enfrentan concept drift: la distribución de los datos cambia con el tiempo. La investigación sobre técnicas de aprendizaje incremental para árboles y regresión logística, preservando la interpretabilidad durante la adaptación, es un área poco explorada con alto potencial práctico en monitoreo continuo, detección de fraude y sistemas de recomendación.

6. Conclusiones

La revisión del estado del arte sobre árboles de decisión y regresión logística arroja varias ideas centrales.

Primera: el supuesto trade-off absoluto entre interpretabilidad y rendimiento predictivo no resiste el escrutinio empírico reciente. Trabajos como los de Rudin (2019), Bell et al. (2022), Assis et al. (2025) y Dziugaite et al. (2020) muestran que los modelos intrínsecamente interpretables pueden competir con los opacos en precisión y tiempo de respuesta cuando se optimizan con cuidado. En dominios de alto riesgo, preferir un modelo interpretable incluso al costo de algunas décimas de precisión es una elección razonable y defendible.

Segunda: los árboles de decisión ofrecen la interpretabilidad operacional más directa. Sus reglas IF-THEN son comprensibles por expertos y no expertos, capturan no linealidades de forma natural y apenas requieren preprocesamiento. Su talón de Aquiles es la alta varianza, que se controla con poda o con métodos de ensamble; estos últimos, sin embargo, sacrifican la interpretabilidad característica del árbol individual.

Tercera: la regresión logística sigue siendo el benchmark por excelencia en medicina, finanzas y ciencias sociales gracias a su base estadística sólida, sus probabilidades calibradas y la interpretabilidad de sus coeficientes. Su limitación principal es la frontera de decisión lineal en el espacio logit, que puede salvarse mediante ingeniería de variables o mediante modelos híbridos como PLTR, LMT o FS-LMT.

Cuarta: el contexto regulatorio emergente (Ley de IA, RGPD) ha elevado la interpretabilidad de atributo deseable a requisito normativo. Los argumentos a favor de los modelos de caja negra con explicaciones post-hoc se debilitan en dominios sensibles, donde los modelos transparentes ofrecen garantías jurídicas que los explicadores a posteriori no pueden prometer.

Quinta: las líneas futuras con mayor proyección son el desarrollo de métricas formales de interpretabilidad, los modelos híbridos árbol-regresión, los árboles óptimos globales, la integración del análisis de eficiencia computacional en la toma de decisiones de modelado y la investigación empírica sobre colaboración humano-algoritmo en contextos de alto riesgo.

En definitiva, la elección entre árbol de decisión y regresión logística, y la posición de cualquier modelo en el espectro interpretabilidad-rendimiento, debe responder a las características específicas del problema: la naturaleza de los datos, el perfil de los usuarios del modelo, las restricciones regulatorias y las consecuencias de los errores de clasificación. No existe un algoritmo universalmente superior. Existe el algoritmo adecuado para cada contexto.

7. Referencias bibliográficas

Assis, A., Dantas, J., & Andrade, E. (2025). The performance-interpretability trade-off: A comparative study of machine learning models. *Journal of Reliable Intelligent Environments, 11*(1), 1. https://doi.org/10.1007/s40860-024-00240-0

Bell, A., Solano-Kamaiko, I., Nov, O., & Stoyanovich, J. (2022). It's just not that simple: An empirical study of the accuracy-explainability trade-off in machine learning for public policy. *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT '22)*, 248–266. https://doi.org/10.1145/3531146.3533090

Bertsimas, D., & Dunn, J. (2017). Optimal classification trees. *Machine Learning, 106*(7), 1039–1082. https://doi.org/10.1007/s10994-017-5633-9

Breiman, L. (1996). Bagging predictors. *Machine Learning, 24*(2), 123–140. https://doi.org/10.1007/BF00058655

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Wadsworth.

Doshi-Velez, F., & Kim, B. (2017). *Towards a rigorous science of interpretable machine learning* (arXiv:1702.08608). arXiv. https://doi.org/10.48550/arXiv.1702.08608

Dumitrescu, E., Hué, S., Hurlin, C., & Tokpavi, S. (2022). Machine learning for credit scoring: Improving logistic regression with non-linear decision-tree effects. *European Journal of Operational Research, 297*(3), 1178–1192. https://doi.org/10.1016/j.ejor.2021.06.053

Dziugaite, G. K., Ben-David, S., & Roy, D. M. (2020). *Enforcing interpretability and its statistical impacts: Trade-offs between accuracy and interpretability* (arXiv:2010.13764). arXiv. https://doi.org/10.48550/arXiv.2010.13764

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). Wiley. https://doi.org/10.1002/9781118548387

Landwehr, N., Hall, M., & Frank, E. (2005). Logistic model trees. *Machine Learning, 59*(1–2), 161–205. https://doi.org/10.1007/s10994-005-0466-3

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). Curran Associates.

Molnar, C. (2022). *Interpretable machine learning: A guide for making black box models explainable* (2nd ed.). https://christophm.github.io/interpretable-ml-book/

Nelder, J. A., & Wedderburn, R. W. M. (1972). Generalized linear models. *Journal of the Royal Statistical Society: Series A (General), 135*(3), 370–384. https://doi.org/10.2307/2344614

Park, K., Kim, S., & Hwang, H. (2023). A novel logistic model tree with separability-based split selection (FS-LMT). *International Journal of Industrial Engineering: Theory, Applications and Practice, 30*(2), 298–311.

Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning, 1*(1), 81–106. https://doi.org/10.1007/BF00116251

Quinlan, J. R. (1993). *C4.5: Programs for machine learning*. Morgan Kaufmann.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, 1135–1144. https://doi.org/10.1145/2939672.2939778

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence, 1*(5), 206–215. https://doi.org/10.1038/s42256-019-0048-x

Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. *Communications of the ACM, 63*(12), 54–63. https://doi.org/10.1145/3381831

Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological), 58*(1), 267–288. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x

Verwer, S., & Zhang, Y. (2019). Learning optimal classification trees using a binary linear program formulation. *Proceedings of the AAAI Conference on Artificial Intelligence, 33*(1), 1625–1632. https://doi.org/10.1609/aaai.v33i01.33011624

Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual explanations without opening the black box: Automated decisions and the GDPR. *Harvard Journal of Law & Technology, 31*(2), 841–887.

Wu, X., Kumar, V., Ross Quinlan, J., Ghosh, J., Yang, Q., Motoda, H., McLachlan, G. J., Ng, A., Liu, B., Yu, P. S., Zhou, Z.-H., Steinbach, M., Hand, D. J., & Steinberg, D. (2008). Top 10 algorithms in data mining. *Knowledge and Information Systems, 14*(1), 1–37. https://doi.org/10.1007/s10115-007-0114-2

Yin, Z., & Babic, B. (2024). *Reframing the accuracy/interpretability trade-off in machine learning* [Working paper]. University of California, Berkeley — University of Toronto. https://borisbabic.com/research/IAT_August2024.pdf

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology), 67*(2), 301–320. https://doi.org/10.1111/j.1467-9868.2005.00503.x