UNIVERSIDAD AUTÓNOMA DE SANTO DOMINGO (UASD)
y UNIVERSIDAD MIGUEL HERMANDEZ (UMH)
FACULTAD DE CIENCIAS - ESCUELA DE INFORMÁTICA
UNIDAD DE POSTGRADO Y EDUCACIÓN PERMANENTE

Doctorado:
PhD en Inteligencia Artificial y Aprendizaje Automático

Asignatura:
INF-9005: Algoritmos de Clasificación en Machine Learning

Práctica 2:
Implementación de un algoritmo de clasificación en un caso real

Laboratorio:
https://colab.research.google.com/drive/1vsLVLVTqf-ALDkl_2VFYb5G2Wy5bWG4H?usp=sharing

Docente:
Dr. Ana Belén

Doctoranda:
Romery Alberto Monegro

Santo Domingo, D. N.
19 de abril del 2026

Resumen

Este trabajo presenta la implementación y comparación de dos algoritmos de clasificación supervisada, árboles de decisión y regresión logística, aplicados al dataset público Student Performance de Cortez y Silva (2008). El caso pertenece al dominio educativo y consiste en predecir si un estudiante de secundaria portugués aprobará la asignatura de Lengua Portuguesa a partir de variables demográficas, familiares, sociales y escolares, sin recurrir a las notas parciales. Se entrenaron seis variantes de modelos: árbol de decisión sin poda y con poda ajustada por validación cruzada, y cuatro versiones de regresión logística que incluyen regresión sin regularización y con penalizaciones L1, L2 y Elastic Net. Los resultados sobre el conjunto de test muestran que el árbol podado y la regresión logística con regularización L2 alcanzan una accuracy del 84 % y un F1 superior a 0.90, empatados en el mejor desempeño. El análisis de sobreajuste, interpretabilidad y coste computacional aporta evidencia directa sobre la investigación de la Práctica 1: los modelos intrínsecamente interpretables pueden competir con alternativas más complejas cuando se optimizan adecuadamente.

Palabras clave: clasificación, árboles de decisión, regresión logística, rendimiento escolar, interpretabilidad, regularización, scikit-learn.

1. Descripción del problema, los datos y el algoritmo

1.1. El problema de la predicción del rendimiento escolar

El rendimiento académico en la educación secundaria es uno de los mayores desafíos de los sistemas educativos contemporáneos. La detección temprana de estudiantes en riesgo de reprobar permite a los centros educativos activar intervenciones focalizadas: refuerzo académico, orientación, tutorías o apoyo familiar. Este tipo de predicción encaja de lleno en el caso número 5 de la Práctica 2 (Educación) y conecta de manera natural con la línea de investigación que he seleccionado, cuyo eje es el compromiso entre interpretabilidad y rendimiento predictivo.

La tarea concreta es una clasificación binaria: dado un conjunto de variables sobre el estudiante, ¿aprobará o no aprobará la asignatura? La interpretabilidad del modelo es un requisito clave en este dominio, no una opción estética. Un algoritmo que etiquete a un adolescente como probable reprobado debe poder justificar esa predicción ante docentes, familias y el propio estudiante. La elección de árboles de decisión y regresión logística no es casual: ambos son modelos intrínsecamente interpretables, cada uno con un mecanismo distinto.

1.2. El dataset Student Performance

El dataset utilizado es Student Performance, publicado por Cortez y Silva (2008) en la UCI Machine Learning Repository bajo licencia Creative Commons Attribution 4.0. Los datos fueron recogidos durante el curso académico 2005-2006 en dos escuelas secundarias públicas de la región portuguesa de Alentejo: Gabriel Pereira (GP) y Mousinho da Silveira (MS). El dataset contiene información recopilada mediante cuestionarios administrados a los estudiantes y consultas a los registros escolares.

El repositorio incluye dos subconjuntos, uno por asignatura: Matemáticas (395 registros) y Lengua Portuguesa (649 registros). Este trabajo utiliza el subconjunto de Lengua Portuguesa por dos razones. Primero, su mayor tamaño muestral ofrece más espacio para analizar la dinámica del sobreajuste. Segundo, dispone de un mayor número de casos de la clase minoritaria, lo que da robustez a las métricas sensibles al desbalance como F1 y AUC-ROC.

El conjunto contiene 33 atributos originales que pueden agruparse en cuatro bloques. El primero reúne variables demográficas como sexo, edad, zona de residencia o tamaño familiar. El segundo captura el entorno socioeducativo: nivel educativo de los padres, profesión, estado civil o nivel de apoyo familiar. El tercero describe hábitos y comportamientos: tiempo de estudio semanal, frecuencia de salidas, consumo de alcohol, ausencias escolares. El cuarto recoge variables propiamente académicas: número de reprobaciones previas, clases particulares, planes de educación superior y las notas parciales G1, G2 y G3.

1.3. Variable objetivo

La nota final G3 se expresa en la escala portuguesa de 0 a 20 puntos, y el umbral oficial de aprobación es 10. A partir de esta escala se construyó una variable binaria aprueba, que toma valor 1 cuando G3 es mayor o igual a 10 y 0 en caso contrario. Siguiendo la recomendación explícita de los autores originales, se eliminaron las variables G1 y G2 (notas parciales del primer y segundo período). Estas notas tienen una correlación tan fuerte con G3 que usarlas como predictoras convertiría el problema en trivial y carente de valor práctico. El escenario realmente útil es anticipar el resultado final antes de disponer de evaluaciones parciales, utilizando únicamente información estructural del estudiante y su entorno.

1.4. Algoritmos seleccionados

Se seleccionaron dos familias de algoritmos estudiados en la asignatura, ambos intrínsecamente interpretables, pero con formulaciones teóricas opuestas. El árbol de decisión, en su formulación CART (Breiman et al., 1984), es un modelo no paramétrico que particiona el espacio de características en regiones rectangulares mediante divisiones binarias recursivas. Su frontera de decisión puede capturar interacciones y no linealidades sin necesidad de ingeniería previa de variables. La regresión logística (Nelder y Wedderburn, 1972; Hosmer et al., 2013) es un modelo paramétrico con una frontera lineal en el espacio logit, estimado por máxima verosimilitud y extensamente utilizado como benchmark en clasificación supervisada.

Esta selección permite contrastar empíricamente dos mecanismos de interpretabilidad distintos. El árbol ofrece reglas IF-THEN visualizables y una estructura jerárquica. La regresión logística proporciona coeficientes con signo, odds ratios y probabilidades calibradas. Ambos se

entrenaron en múltiples configuraciones para explorar el efecto de la regularización: el árbol con y sin poda, y la regresión logística sin regularización, con L1 (Lasso), con L2 (Ridge) y con Elastic Net.

2. Justificación del preprocesamiento

El preprocesamiento aplicado al dataset se diseñó teniendo en cuenta las características específicas de cada algoritmo y la naturaleza de las variables disponibles. No se realizó ninguna imputación de valores perdidos porque el dataset no contiene ninguno (se verificó con df.isnull().sum()), lo cual simplifica considerablemente el flujo.

2.1. Codificación de variables categóricas

De las 32 variables predictoras, 17 son categóricas nominales (escuela, sexo, tipo de dirección, trabajo de los padres, motivo de elección de la escuela, entre otras) y 15 son numéricas. Los árboles de decisión pueden manejar variables categóricas de forma nativa mediante particiones binarias por categoría, pero la implementación de scikit-learn utilizada en este trabajo requiere una representación numérica. La regresión logística, por su parte, siempre requiere codificación numérica.

Se aplicó one-hot encoding con el parámetro drop_first=True para evitar la colinealidad perfecta conocida como trampa de las variables ficticias. Si una variable categórica tiene k categorías, drop_first genera k-1 columnas binarias y utiliza la categoría omitida como referencia. Esta decisión es especialmente importante para la regresión logística, donde la colinealidad perfecta produce inestabilidad numérica en la matriz de diseño. Tras la codificación, la matriz de características pasó de 32 columnas originales a 39 columnas finales.

2.2. Estandarización de variables numéricas

El escalado es necesario únicamente para la regresión logística. Los árboles de decisión son invariantes a transformaciones monótonas de las variables porque sus divisiones dependen solo de umbrales relativos: partir en edad igual a 17 produce exactamente las mismas hojas que partir en edad estandarizada igual a 0.34. La regresión logística, en cambio, es sensible a la escala de las variables por dos motivos. Primero, los coeficientes se interpretan en relación a la magnitud

de las variables, y comparar un coeficiente asociado a edad (rango 15-22) con uno asociado a Medu (rango 0-4) pierde todo sentido sin estandarización. Segundo, la regularización L1 y L2 penalizan la magnitud de los coeficientes, por lo que variables con rangos grandes recibirían una penalización proporcional mayor de manera artificial.

La estandarización se implementó con StandardScaler de scikit-learn, que transforma cada variable para tener media cero y desviación estándar uno. El ajuste (.fit) se realizó exclusivamente sobre el conjunto de entrenamiento para evitar fugas de información, y la misma transformación se aplicó al conjunto de test.

2.3. División en conjuntos de entrenamiento y test

Los datos se dividieron en 75 % para entrenamiento (486 registros) y 25 % para test (163 registros). La división se realizó de forma estratificada con train_test_split(stratify=y), lo que preserva la proporción de aprobación en ambos conjuntos. Este paso es crítico dado el desbalance de clases observado: aproximadamente el 85 % de los estudiantes del dataset aprueba. Una división no estratificada podría, por azar, colocar una proporción desigual de la clase minoritaria en cada partición y distorsionar las métricas de evaluación.

Se fijó una semilla aleatoria (random_state=42) para garantizar la reproducibilidad del experimento. Todos los modelos, incluyendo las búsquedas por grilla y las curvas de aprendizaje, utilizan la misma semilla.

2.4. Búsqueda de hiperparámetros

La selección de hiperparámetros se realizó mediante GridSearchCV con validación cruzada estratificada de 5 pliegues, utilizando F1 como métrica objetivo. F1 se prefiere a accuracy en este contexto porque el dataset está desbalanceado: un clasificador que prediga siempre la clase mayoritaria alcanzaría un 85 % de accuracy sin aprender nada útil. El F1 obliga al modelo a equilibrar precisión y recall sobre la clase minoritaria (los no aprobados), que es precisamente la clase operativamente más importante para el caso de uso educativo.

3. Resultados

3.1. Análisis descriptivo

El dataset contiene 649 observaciones sin valores perdidos. Tras la eliminación de las notas parciales y la construcción de la variable objetivo, quedan 32 variables predictoras. La distribución de la clase objetivo presenta desbalance moderado: 549 estudiantes aprobaron la asignatura (84.6 %) y 100 no lo hicieron (15.4 %). La figura 1 muestra esta distribución.

Figura 1

Distribución de la variable objetivo en el dataset (n = 649)

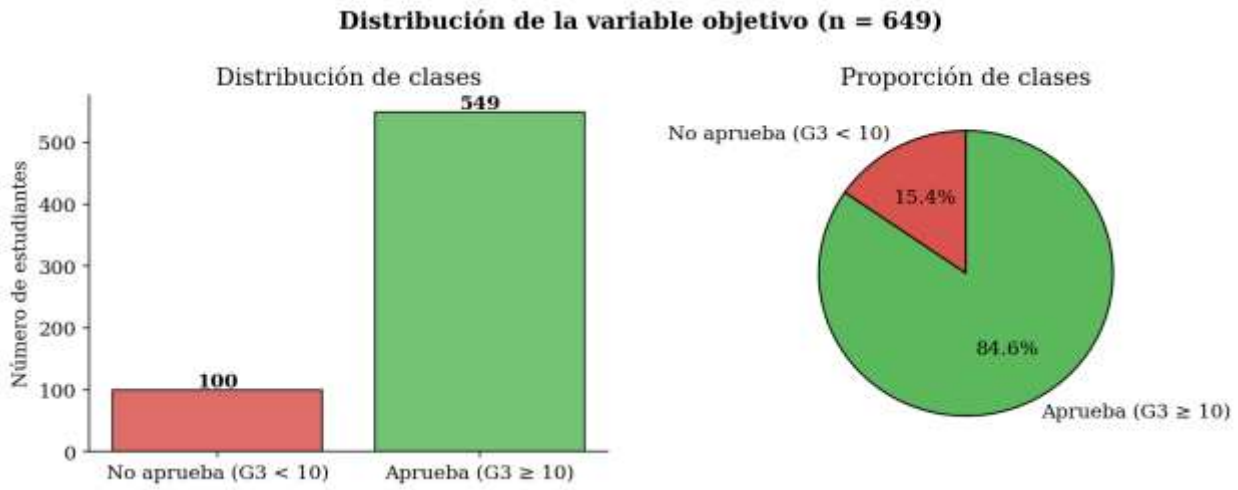

La figura 2 presenta la distribución de seis variables numéricas clave por clase. El patrón más evidente aparece en failures (reprobaciones previas): los estudiantes aprobados concentran la mayor parte de su masa en cero reprobaciones, mientras que los no aprobados están distribuidos de manera mucho más uniforme en valores altos. También se observan diferencias notables en absences (ausencias) y studytime (tiempo de estudio), aunque con solapamiento considerable.

Figura 2

Distribución de variables numéricas clave según la clase objetivo

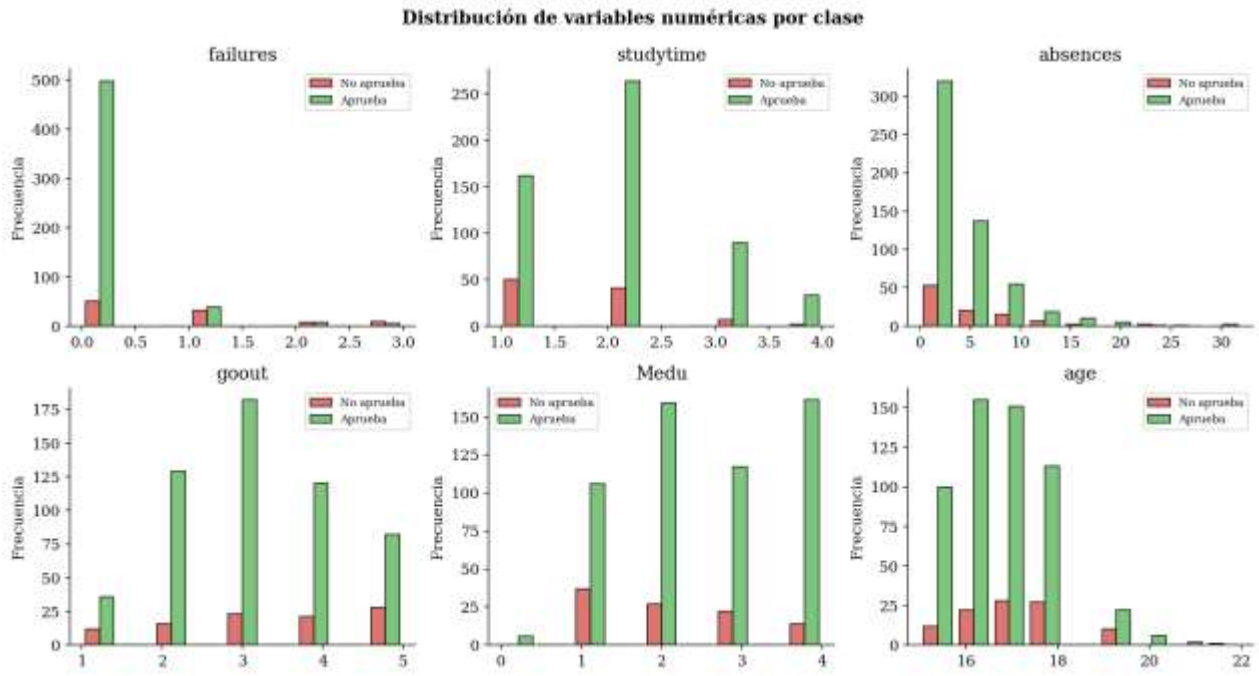

3.2. Resultados predictivos

La tabla 1 presenta las métricas de evaluación obtenidas por los seis modelos entrenados sobre el conjunto de test. Todos los valores corresponden a datos no vistos durante el entrenamiento ni durante la búsqueda de hiperparámetros.

Tabla 1

Métricas de evaluación de los seis modelos entrenados, sobre el conjunto de test

Modelo	Accuracy	Precisión	Recall	F1	AUC-ROC
Árbol sin poda	0.785	0.881	0.862	0.872	0.611
Árbol con poda	0.840	0.884	0.935	0.908	0.748
RL sin regularización	0.798	0.867	0.899	0.883	0.675
RL + L2 (Ridge)	0.840	0.854	0.978	0.912	0.664

Modelo	Accuracy	Precisión	Recall	F1	AUC-ROC
RL + L1 (Lasso)	0.816	0.855	0.942	0.897	0.729
RL + Elastic Net	0.828	0.857	0.957	0.904	0.725

El árbol podado y la regresión logística con regularización L2 empatan en accuracy (0.840) y F1 (por encima de 0.90). Ambos superan por un margen considerable al árbol sin poda, que sufre de sobreajuste, y a la regresión logística sin regularización. La regresión logística con L1 alcanza la mejor AUC-ROC entre las variantes logísticas (0.729), mientras que el árbol podado obtiene la mejor AUC-ROC global (0.748).

La figura 3 presenta las matrices de confusión de los dos modelos empatados en primer lugar. Ambos clasifican correctamente a la mayoría de los estudiantes aprobados, pero la detección de los no aprobados es más limitada, lo cual es consistente con el desbalance de clases y con el perfil moderado de las AUC.

Figura 3

Matrices de confusión de los modelos con mejor rendimiento

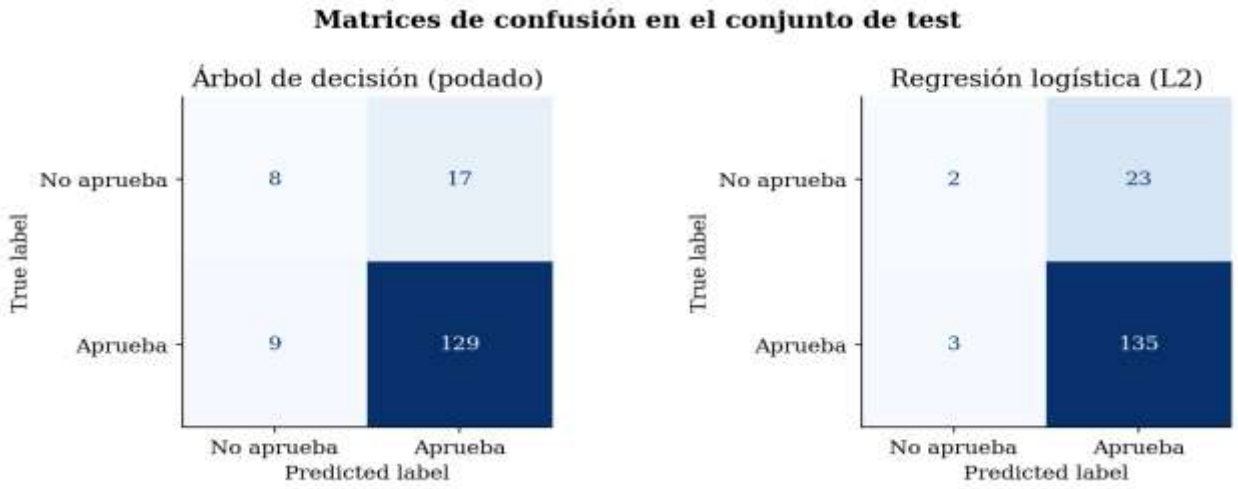

La figura 4 muestra las curvas ROC de los cuatro modelos más relevantes. El árbol podado y la regresión logística con L1 presentan las mejores curvas, especialmente en la zona de alta especificidad (ángulo superior izquierdo), que es la región operativamente relevante para este caso: se busca identificar con alta confianza a los estudiantes en riesgo sin generar demasiadas falsas alarmas.

Figura 4

Curvas ROC de los modelos evaluados

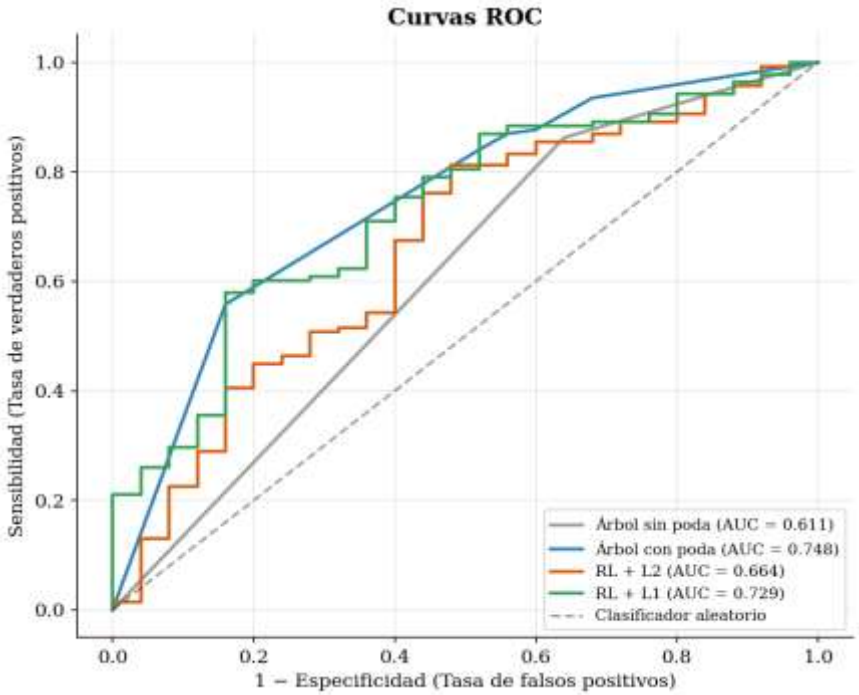

4. Análisis del sobreajuste, la interpretabilidad y el coste computacional

4.1. Sobreajuste

El fenómeno del sobreajuste se manifiesta con claridad en el árbol de decisión sin poda, que alcanza una accuracy de 1.000 en entrenamiento frente a 0.785 en test. Esta brecha de casi 22 puntos porcentuales es una señal inequívoca de que el modelo está memorizando el ruido del conjunto de entrenamiento en lugar de aprender patrones generalizables. El árbol sin restricciones

crece hasta una profundidad de 10 niveles con 54 nodos hoja, un tamaño excesivo para un dataset con solo 486 observaciones de entrenamiento.

La búsqueda por grilla identifica como mejor configuración una combinación de max_depth=3, min_samples_leaf=20 y criterio Gini. El árbol resultante tiene apenas 6 nodos hoja, pero su accuracy de test sube al 84 % y su F1 a 0.908. La figura 5 ilustra la diferencia con curvas de aprendizaje: a la izquierda, el árbol sin poda mantiene un train accuracy constante de 1.0 mientras la validación se estanca cerca del 82 %; a la derecha, ambas curvas convergen por encima del 85 %, señal de generalización sana.

Figura 5

Curvas de aprendizaje que evidencian el sobreajuste del árbol sin poda y su mitigación tras la poda

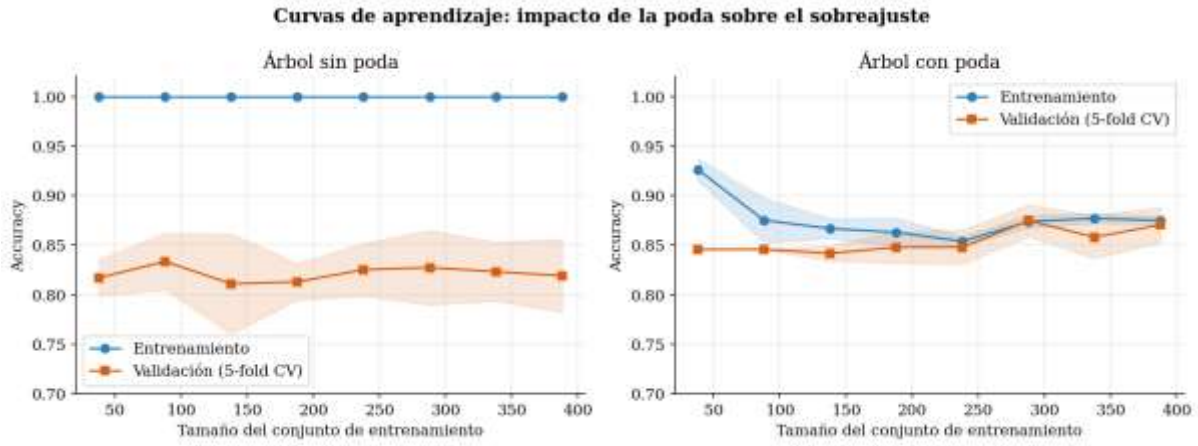

En la regresión logística el sobreajuste es menos severo por la naturaleza paramétrica del modelo, pero también aparece: sin regularización, el train accuracy alcanza 0.899 frente a 0.798 en test, una brecha de 10 puntos. La regularización reduce drásticamente esta brecha. La penalización L2 produce la mejor combinación: 0.864 en train y 0.840 en test, con solo 2.4 puntos de diferencia. La penalización L1 actúa de manera más agresiva, anulando el 71.8 % de los coeficientes del modelo. La figura 6 muestra el árbol podado final.

Figura 6

Árbol de decisión podado final (profundidad 3, 6 hojas)

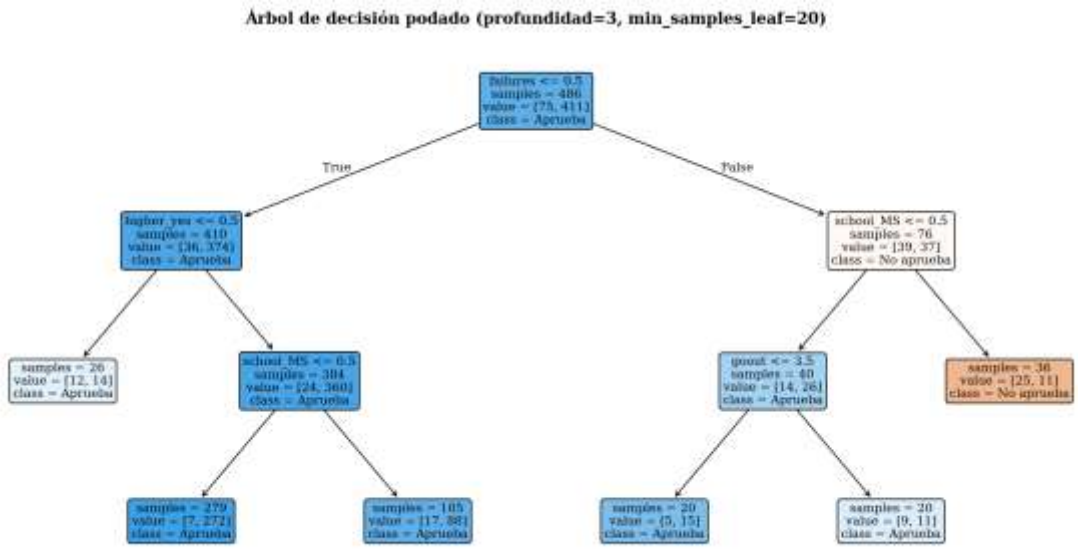

4.2. Interpretabilidad

Los dos modelos ofrecen interpretabilidad, pero por vías distintas. El árbol podado expone reglas IF-THEN directamente comprensibles. La raíz del árbol divide en función de failures, la variable con mayor ganancia de información: los estudiantes sin reprobaciones previas forman un subgrupo mayoritariamente aprobado, y los que tienen reprobaciones se dividen después por escuela (school_MS) y por intención de continuar estudios superiores (higher). Un docente puede leer este árbol y describir en lenguaje natural la regla de clasificación sin conocimientos técnicos.

La regresión logística con L2 ofrece una interpretación distinta. Sus coeficientes, estandarizados para ser comparables, indican la dirección y magnitud del efecto de cada variable sobre el logit. El coeficiente negativo más grande corresponde a failures (-0.298), seguido por school_MS (-0.271), lo que confirma a escala global lo que el árbol muestra localmente. Los coeficientes positivos más fuertes son higher_yes (+0.239) y reason_reputation (+0.111). La figura 7 compara las importancias de ambos modelos.

Figura 7

Importancias de variables en el árbol podado (izquierda) y coeficientes estandarizados en la regresión logística L2 (derecha)

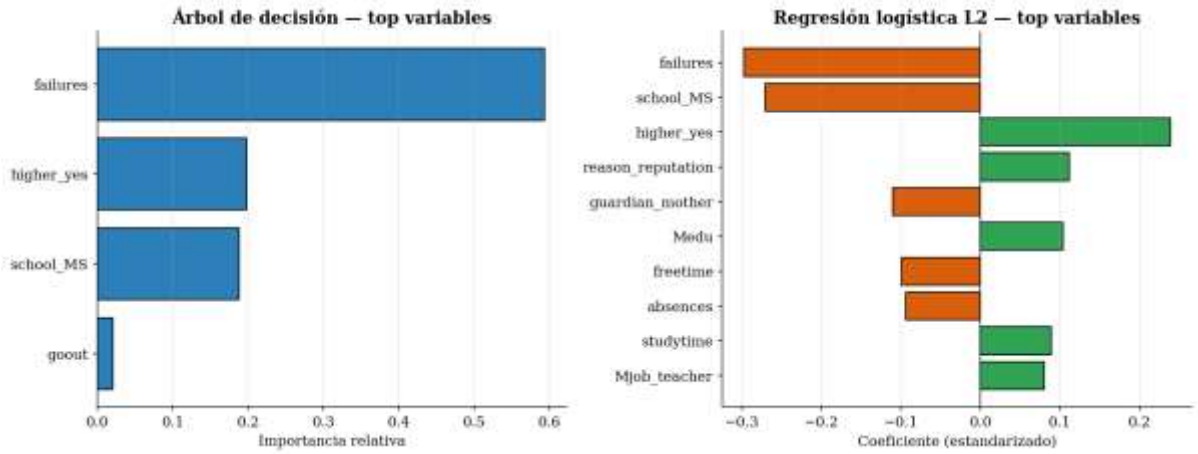

Una propiedad notable de la regularización L1 es su capacidad de hacer selección automática de variables al anular coeficientes. La figura 8 ilustra el efecto de variar el parámetro de regularización C: conforme C disminuye (más regularización), más coeficientes convergen a cero. En el mejor C encontrado por GridSearch, 28 de las 39 variables tienen coeficiente cero, dejando solo 11 variables activas en el modelo final.

Figura 8

Efecto de la penalización L1 sobre los coeficientes en función del parámetro C

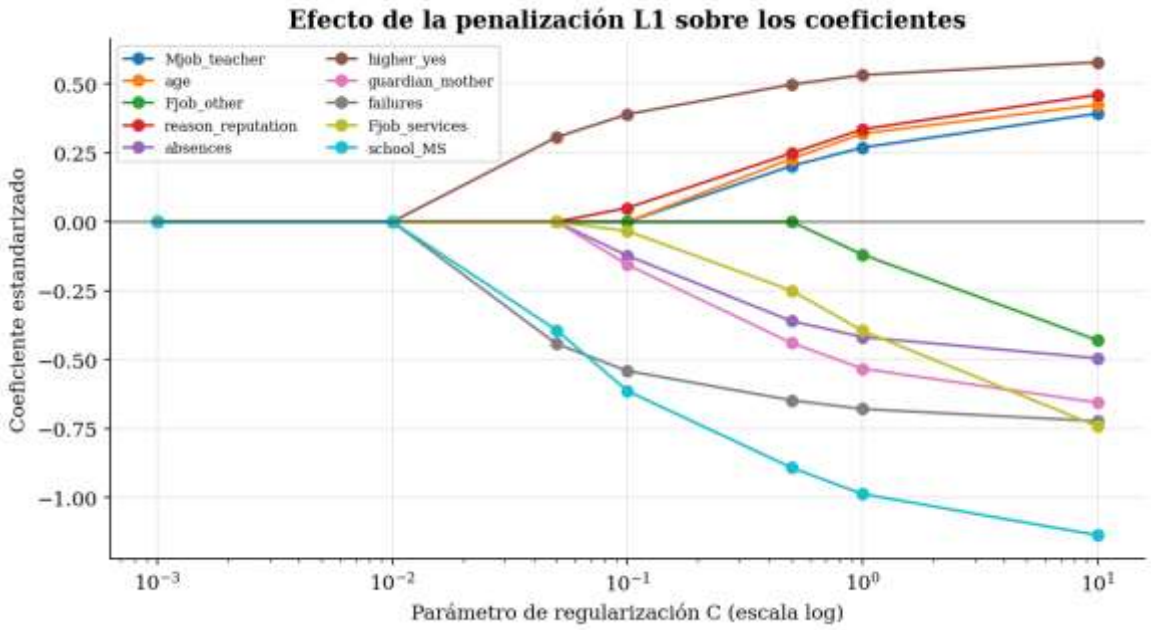

En el contexto educativo, esta capacidad de selección es especialmente valiosa. Un modelo que identifica explícitamente 11 variables relevantes de entre 39 posibles ofrece un mensaje operativo claro al centro escolar: estas son las señales que importan. Por contraste, un modelo opaco podría ofrecer un rendimiento similar sin indicar qué intervenir.

4.3. Coste computacional

El entrenamiento individual de un árbol de decisión o una regresión logística sobre este dataset es extremadamente rápido: pocos milisegundos en ambos casos. El tiempo medido del árbol sin poda fue de 2.7 ms, y el de la regresión logística sin regularización, 6.2 ms. El coste real del flujo de trabajo aparece en la búsqueda de hiperparámetros por validación cruzada.

La búsqueda por grilla del árbol, con 42 combinaciones y 5 pliegues (210 entrenamientos), tomó 10.3 segundos. La búsqueda de la regresión logística con L2, con 6 combinaciones y 5 pliegues (30 entrenamientos), tomó 0.29 segundos. Esta diferencia de órdenes de magnitud entre entrenamiento base y búsqueda de hiperparámetros es una observación directamente relevante para la Práctica 3 sobre Green AI: casi todo el coste computacional del flujo proviene de la selección de modelo, no del algoritmo en sí.

La tabla 2 resume los tiempos medidos. Todas las mediciones se tomaron en una sesión de Google Colab con CPU estándar.

Tabla 2

Tiempo de entrenamiento de cada modelo

Modelo	Tiempo	Detalle
Árbol sin poda	2.7 ms	Entrenamiento único
Árbol con poda (GridSearch)	10.3 s	42 combinaciones × 5 pliegues
RL sin regularización	6.2 ms	Entrenamiento único

Modelo	Tiempo	Detalle
RL + L2 (GridSearch)	0.29 s	6 combinaciones × 5 pliegues
RL + L1 (GridSearch)	0.22 s	6 combinaciones × 5 pliegues
RL + Elastic Net (GridSearch)	1.12 s	9 combinaciones × 5 pliegues

La regresión logística escala más favorablemente que el árbol en este tipo de problemas tabulares: menos combinaciones por explorar (solo el parámetro C) y entrenamientos internos más rápidos. El árbol, en cambio, exige la búsqueda simultánea sobre criterio, profundidad máxima y mínimo de muestras por hoja, lo que expande la grilla.

4.4. Síntesis

El experimento da soporte empírico a la investigación central de la Práctica 1. Los dos modelos intrínsecamente interpretables alcanzan un desempeño equivalente sobre este problema de clasificación escolar, y superan en generalización a sus variantes sin regularización. En un dominio sensible como la educación, donde las predicciones tienen consecuencias reales para adolescentes y sus familias, la combinación de rendimiento y explicabilidad que ofrecen el árbol podado y la regresión logística regularizada es difícil de justificar cambiar por un modelo más opaco. La pequeña ganancia potencial en precisión que podría ofrecer un Random Forest o un XGBoost difícilmente compensa la pérdida de capacidad de explicar cada predicción a un consejo escolar.

5. Referencias bibliográficas

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Wadsworth.

Cortez, P., & Silva, A. M. G. (2008). Using data mining to predict secondary school student performance. En A. Brito y J. Teixeira (Eds.), *Proceedings of 5th Future Business Technology Conference (FUBUTEC 2008)* (pp. 5-12). EUROSIS.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*(7825), 357-362. https://doi.org/10.1038/s41586-020-2649-2

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley. https://doi.org/10.1002/9781118548387

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90-95. https://doi.org/10.1109/MCSE.2007.55

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56-61). https://doi.org/10.25080/Majora-92bf1922-00a

Nelder, J. A., & Wedderburn, R. W. M. (1972). Generalized linear models. *Journal of the Royal Statistical Society: Series A (General), 135*(3), 370-384. https://doi.org/10.2307/2344614

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D.,

Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence, 1*(5), 206-215. https://doi.org/10.1038/s42256-019-0048-x

Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological), 58*(1), 267-288.

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the Elastic Net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology), 67*(2), 301-320. https://doi.org/10.1111/j.1467-9868.2005.00503.x